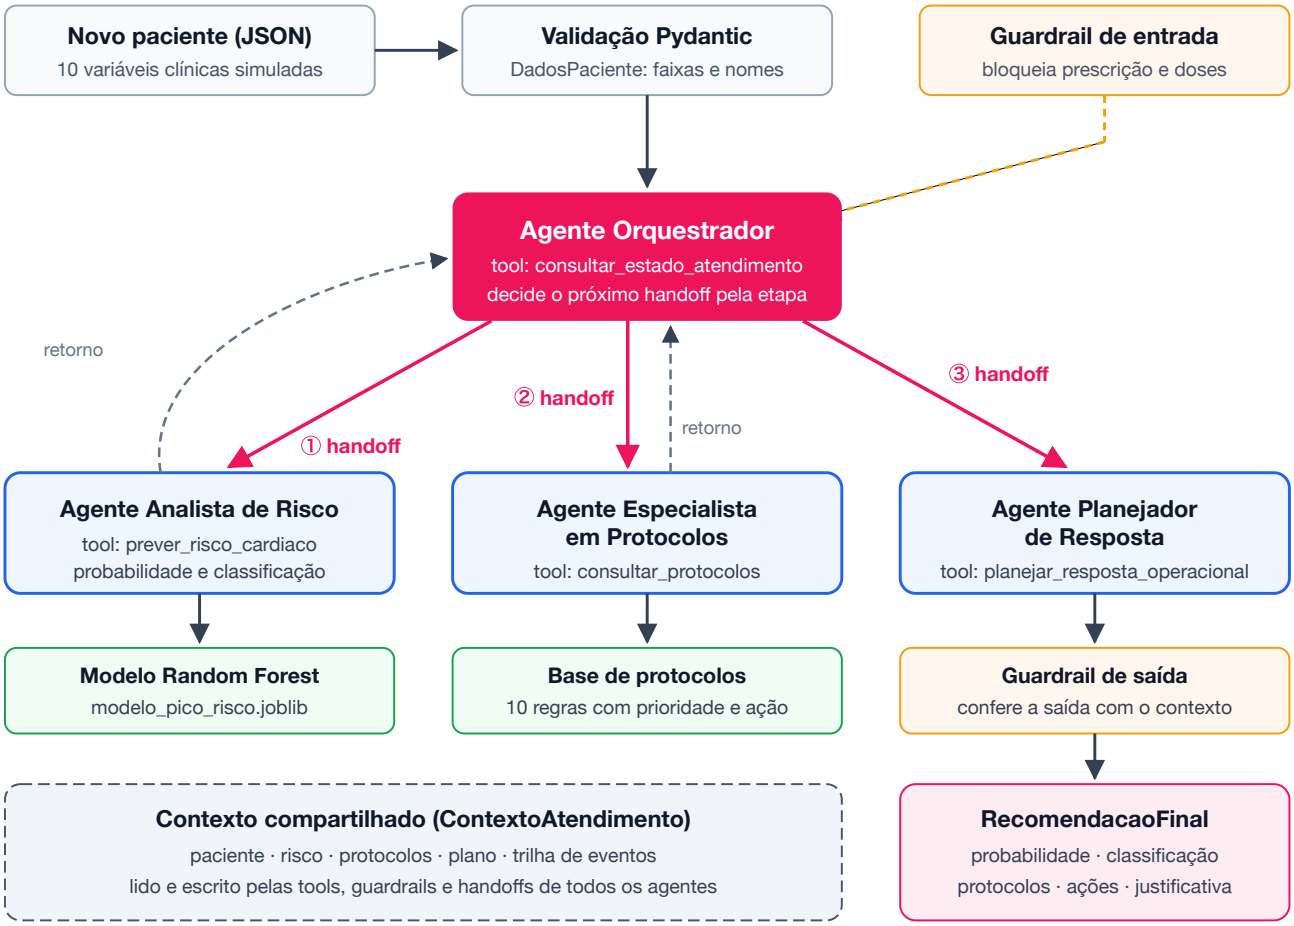
Arquitetura do Sistema Preditivo Multiagente para Eventos Cardíacos

FIAP · Graduação em IA · Fase 6 · Parte 2: OpenAI Agents SDK

1. Diagrama da arquitetura



Setas sólidas em rosa: handoffs do Orquestrador, na ordem ①, ② e ③. Setas tracejadas: o Analista e o Especialista devolvem o controle ao Orquestrador. O histórico de mensagens de cada atendimento fica em uma `SQLiteSession`, o que permite perguntas de acompanhamento depois da recomendação.

2. Papel de cada agente

Agente	Tools e recursos	Responsabilidade
Orquestrador	`consultar_estado_atendimento`, guardrail de entrada, 3 handoffs	Ponto de entrada. A cada turno consulta a etapa atual no contexto e transfere para o especialista certo. Depois da recomendação, responde perguntas de acompanhamento usando o histórico da sessão. Nunca calcula risco nem escolhe protocolos.
Analista de Risco	`prever_risco_cardiaco` e o modelo Random Forest	Chama o modelo de ML treinado na Parte 1, grava no contexto a probabilidade, a classificação (BAIXO, MODERADO ou ALTO) e os fatores de risco, e devolve o controle ao Orquestrador.
Especialista em Protocolos	`consultar_protocolos` e a base de protocolos	Cruza os dados do paciente e o risco previsto com as 10 regras da base. Grava os protocolos acionados, por prioridade, e os parâmetros em zona de atenção, que estão perto do limite sem acioná-lo.
Planejador de Resposta	`planejar_resposta_operacional`, `output_type` e guardrail de saída	Converte cada protocolo em ação operacional com responsável e prazo. Produz a `RecomendacaoFinal` estruturada, com justificativa em linguagem natural, e encerra o fluxo.

3. Uso de handoffs, tools, histórico e validação

- **Handoffs.** A topologia é *hub-and-spoke*. Cada handoff do Orquestrador usa `is_enabled` e só fica disponível na etapa certa: análise de risco, depois protocolos, depois plano. Assim, o LLM não consegue pular etapas nem repetir a predição. Cada handoff tem um `on_handoff` que registra a transferência na trilha.
- **Tools.** As quatro tools são `@function_tool` que leem os dados do paciente do contexto compartilhado (`RunContextWrapper`). O LLM decide *quando* chamar cada tool, mas não digita valores clínicos. Isso elimina erros de transcrição e garante que o resultado da predição seja o mesmo para todos os agentes.
- **Histórico de mensagens.** Cada atendimento usa uma `SQLiteSession` gravada em `data/historico_atendimentos.db`. No modo `--interativo`, perguntas como "por que o risco ficou alto?" são respondidas pelo Orquestrador com base nesse histórico.
- **Validação de saída.** A validação acontece em três camadas. A primeira é o Pydantic na entrada. A segunda é o `output_type=RecomendacaoFinal`, que obriga o LLM a responder em JSON com esse esquema. A terceira é o guardrail de saída, que compara probabilidade, classificação, protocolos e ações com o contexto. Se houver divergência, o tripwire dispara e o sistema usa a recomendação montada direto do contexto validado.
- **Resiliência.** Se algum agente responder em texto em vez de transferir, o sistema retoma o fluxo pelo Orquestrador, que consulta a etapa atual e continua de onde parou, com até 2 retomadas.

4. Exemplo de entrada e saída

Entrada: o paciente do enunciado, arquivo `data/pacientes/novo_caso_enunciado.json`. A chave `"disponibilidade recursos"`, com espaço, é normalizada pela validação.

```
{"idade_media": 62, "carga_sistema": 92, "tempo_espera": 75, "fc_media": 118, "spo2_media": 89,
 "pa_sistolica": 100, "temperatura": 37.5, "densidade_eventos": 7, "eventos_24h": 5,
 "disponibilidade recursos": 25}
```

Trilha de execução impressa pelos hooks do Runner:

```
[agente]  Agente Orquestrador assumiu o atendimento
[tool]    Agente Orquestrador chamou consultar_estado_atendimento
[handoff] Agente Orquestrador → Agente Analista de Risco
[tool]    Agente Analista de Risco chamou prever_risco_cardiaco
[handoff] Agente Analista de Risco → Agente Orquestrador
[tool]    Agente Orquestrador chamou consultar_estado_atendimento
[handoff] Agente Orquestrador → Agente Especialista em Protocolos
[tool]    Agente Especialista em Protocolos chamou consultar_protocolos
[handoff] Agente Especialista em Protocolos → Agente Orquestrador
[tool]    Agente Orquestrador chamou consultar_estado_atendimento
[handoff] Agente Orquestrador → Agente Planejador de Resposta
[tool]    Agente Planejador de Resposta chamou planejar_resposta_operacional
Guardrail de saída: aprovado
```

Saída final do Agente Planejador de Resposta:

```
RISCO PREVISTO: 0.99
CLASSIFICAÇÃO DE RISCO: ALTO

FATORES DE RISCO IDENTIFICADOS:
- Carga do sistema acima de 80% (valor: 92)
- Tempo de espera acima de 60 min (valor: 75)
- SpO2 abaixo de 92% (valor: 89)
- Frequência cardíaca acima de 110 bpm (valor: 118)
- Mais de 4 eventos nas últimas 24 h (valor: 5)
- Disponibilidade de recursos abaixo de 40% (valor: 25)

PROTOCOLOS SUGERIDOS:
- Se risco sistêmico alto → ativar estado de emergência
- Se carga do sistema > 85% → abrir unidades temporárias
- Se disponibilidade_recursos < 30% → redistribuir insumos
- Se densidade_eventos > 6 → ativar plano de contingência

AÇÕES OPERACIONAIS:
[P2] Declarar estado de emergência e comunicar a direção clínica   (Direção clínica, até 30 min)
[P3] Abrir leitos e unidades temporárias para absorver a demanda   (Gestão de leitos, até 2 h)
[P3] Redistribuir insumos e equipamentos entre as unidades         (Farmácia e logística, até 1 h)
[P3] Ativar o plano de contingência e reforçar escalas             (Coordenação de plantão, até 1 h)

PARÂMETROS EM ZONA DE ATENÇÃO:
- spo2_media = 89% (limite < 88%, protocolo P01 ainda não acionado)
- fc_media = 118 bpm (limite > 120 bpm, protocolo P03 ainda não acionado)
- eventos_24h = 5 eventos (limite > 5 eventos, protocolo P04 ainda não acionado)
- tempo_espera = 75 min (limite > 90 min, protocolo P06 ainda não acionado)
- temperatura = 37.5 °C (limite > 38 °C, protocolo P07 ainda não acionado)
- pa_sistolica = 100 mmHg (limite < 90 mmHg, protocolo P09 ainda não acionado)
```

A saída também traz uma justificativa em linguagem natural, redigida pelo LLM, e o aviso de que se trata de apoio à decisão com dados simulados. O texto da justificativa varia entre execuções. Os números, protocolos e ações não variam, porque vêm do contexto e são conferidos pelo guardrail de saída.

Diferença em relação ao exemplo do enunciado. O enunciado lista o protocolo de SpO2, mas o paciente tem SpO2 de 89%, acima do limite de 88%. O sistema aplica as regras à risca e mostra a SpO2 como parâmetro em zona de atenção. Pelo mesmo critério, o sistema acrescenta o plano de contingência, pois a densidade de eventos é 7, acima de 6, e o estado de emergência, pois o risco previsto é ALTO.