Relatório Técnico: Modelo Preditivo de Pico de Risco Cardíaco

FIAP · Graduação em IA · Fase 6 · Sistema Preditivo Multiagente para Eventos Cardíacos

1. Dados e preparação

Usamos a base sintética do enunciado, gerada com semente 42: 5.000 registros, 10 variáveis numéricas e o alvo binário `pico_risco`. O alvo vale 1 quando pelo menos dois de seis critérios estão presentes: carga > 80%, espera > 60 min, SpO2 < 92%, FC > 110 bpm, eventos 24 h > 4 e recursos < 40%. A base não tem valores ausentes e é desbalanceada, com 26,6% de picos. Por isso, a separação treino/teste (80/20) foi **estratificada**, o que manteve 26,6% de picos nos dois conjuntos. Não foi necessário padronizar as variáveis para modelos baseados em árvores. Para a Regressão Logística usamos `StandardScaler` dentro de um `Pipeline`, ajustado só no treino, para evitar vazamento de dados.

2. Justificativa do algoritmo

Comparamos três classificadores supervisionados com validação cruzada estratificada de 5 folds no treino. Em seguida, avaliamos cada um no conjunto de teste, que não foi usado em nenhuma decisão anterior.

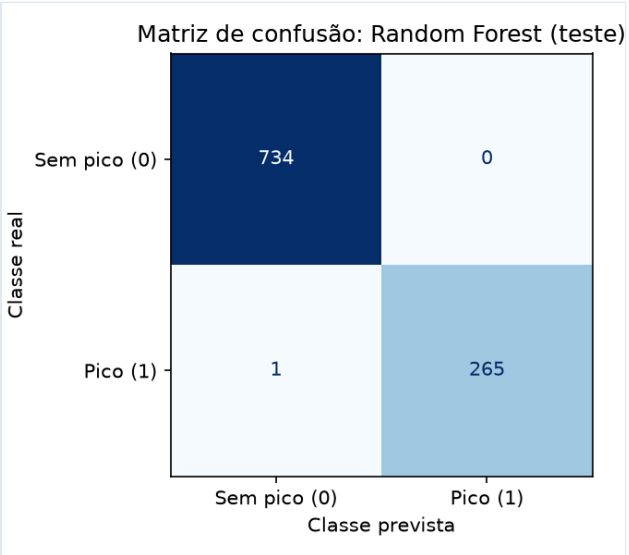
Modelo	F1 (CV, média ± dp)	Acurácia	Precisão	Recall	F1	ROC AUC
Regressão Logística	0,643 ± 0,031	0,816	0,693	0,553	0,615	0,872
Árvore de Decisão (prof. 6)	0,993 ± 0,003	0,997	0,996	0,992	0,994	0,996
Random Forest (300 árvores)	**0,995 ± 0,002**	**0,999**	**1,000**	**0,996**	**0,998**	**1,000**

Escolhemos o **Random Forest** por três motivos. Primeiro, o alvo é construído com **limites por variável** e uma contagem de critérios. Esse padrão é exatamente o que uma árvore aprende com seus cortes, enquanto a fronteira "2 de 6 critérios" não é linear, o que explica o F1 de apenas 0,64 da Regressão Logística. Segundo, o ensemble de árvores tem variância menor que uma árvore isolada, o que se vê no menor desvio entre os folds. Terceiro, ele produz **probabilidades** via `predict_proba`, que o sistema multiagente usa para classificar o risco em BAIXO (< 0,30), MODERADO (0,30 a 0,69) e ALTO (≥ 0,70).

3. Interpretação das métricas

- **Acurácia de 99,9%**: o modelo errou 1 de 1.000 casos de teste. Como a base é desbalanceada, essa métrica sozinha não basta, pois um modelo que dissesse sempre "sem pico" já teria 73,4% de acurácia.
- **Recall de 99,6%** na classe de pico é a métrica mais importante neste domínio, porque mede quantos picos reais foram detectados. Deixar de sinalizar um pico custa mais que um alarme falso.
- **Precisão de 100%**: todo alerta emitido no teste correspondia a um pico real, sem alarmes falsos.
- **ROC AUC de 1,00**: as probabilidades ordenam perfeitamente os casos, o que valida o uso de faixas de probabilidade.

4. Análise da matriz de confusão



No conjunto de teste, com 1.000 casos:

- **734 verdadeiros negativos**: casos sem pico corretamente descartados.
- **265 verdadeiros positivos**: picos corretamente detectados.
- **0 falsos positivos**: nenhum alarme desnecessário.
- **1 falso negativo**: um único pico não detectado. É um caso de fronteira: carga de 90,8% e tempo de espera de 60,009 min, apenas 0,009 min acima do limite de 60. O modelo deu probabilidade de 0,45. Com o limiar padrão de 0,5 ele vira falso negativo, mas o sistema multiagente o classifica como risco **MODERADO**, e não BAIXO, o que ainda gera alerta.

A importância das variáveis confirma que o modelo aprendeu a estrutura certa. Carga, recursos, espera e SpO2 somam 83% da importância. FC e eventos 24 h vêm em seguida, porque seus limites são raros na base. Idade, PA, temperatura

e densidade de eventos não fazem parte da regra e ficam com importância próxima de zero.

5. Limitações

- **Desempenho otimista.** O alvo é uma função determinística e sem ruído das próprias entradas. O modelo essencialmente redescobre a regra de geração. Em dados reais, com erro de medição e fatores não observados, as métricas seriam bem menores.
- **Variáveis sem relação clínica.** A temperatura simulada tem média de 24 °C, valor que parece ambiental e não corporal. Idade e PA não influenciam o alvo, embora sejam fatores de risco cardíaco conhecidos.
- **Mistura de níveis.** As variáveis misturam dados do paciente, como FC e SpO2, com dados do sistema, como carga e recursos. Isso dificulta interpretar o resultado como risco individual.
- **Sensibilidade aos limites.** Pequenas variações perto dos cortes mudam a previsão de forma brusca. No paciente de exemplo de risco moderado, um tempo de espera de 60 min gera probabilidade de 0,40, enquanto 61 min gera 0,95.
- **Sem calibração nem validação externa.** As probabilidades não foram calibradas e o modelo não foi testado em outra população.

6. Melhorias propostas

- Treinar com dados reais ou com uma base sintética que inclua ruído e rótulos clínicos, e repetir a validação.
- Calibrar as probabilidades com `CalibratedClassifierCV` e escolher o limiar de decisão pela curva precisão-recall, priorizando o recall.
- Ajustar hiperparâmetros com `GridSearchCV` e explicar previsões individuais com SHAP.
- Separar variáveis do paciente e do sistema em modelos distintos ou em agentes distintos.
- Monitorar desvio de dados (*data drift*) em produção e retreinar periodicamente.